INFORME METODOLÓGICO

Minería de Datos | Proyecto de Aula LexaVoxa

1. Introducción y problema

LexaVoxa es un aplicativo web orientado al aprendizaje de idiomas que busca contribuir a mejorar la motivación, la constancia y el seguimiento del progreso de los estudiantes durante su proceso de formación. Como parte de la integración del componente analítico en el proyecto, este ejercicio explora cómo los registros históricos de rendimiento estudiantil pueden aportar a la comprensión y predicción del éxito académico de los estudiantes.

- **Pregunta de análisis:** ¿Cómo se puede predecir la calificación final (G3) de un estudiante a partir de su tiempo de estudio semanal, ausencias y calificaciones previas en el dataset seleccionado?
- **Tipo de tarea:** Regresión
- **Variable objetivo:** G3 (Calificación final del período, en una escala de 0 a 20)

2. Fuente y descripción de los datos

La fuente de datos utilizada es el dataset "Student Performance" (*student-por.csv*) obtenido del UCI Machine Learning Repository, enfocado en el rendimiento académico en lengua portuguesa.

- **Volumen:** 649 registros (filas) y 33 columnas.
- **Variables Numéricas (16):** age, Medu, Fedu, traveltime, studytime, failures, famrel, freetime, goout, Dalc, Walc, health, absences, G1, G2, G3.
- **Variables Categóricas (17):** school, sex, address, famsize, Pstatus, Mjob, Fjob, reason, guardian, schoolsup, famsup, paid, activities, nursery, higher, internet, romantic.
- **Calidad de datos:** El conjunto de datos original no presenta valores nulos. Las variables numéricas reflejan de forma consistente los hábitos y antecedentes académicos de los estudiantes. Los valores monetarios o numéricos extremos en ausencias u otras variables se conservaron al representar comportamientos reales dentro del entorno educativo.
- **Privacidad:** Se excluyeron variables o identificadores que comprometan información confidencial directa, enfocando el análisis exclusivamente en el comportamiento de estudio y rendimiento.

3. Metodología y herramientas

Se siguió una secuencia inspirada en las seis etapas de la guía de la asignatura: definir el problema, revisar los datos, preparar variables, modelar, evaluar y reportar. El análisis estadístico y el experimento de regresión se ejecutaron utilizando Python, pandas y scikit-learn a través de la herramienta de apoyo MinedApp.

4. Exploración y preparación

El archivo contiene 649 filas y 33 columnas. No se detectaron valores nulos en el dataset original. El análisis exploratorio de la distribución de edades (age) muestra una concentración principal de estudiantes entre los 15 y 18 años. La matriz de correlación evidencia una relación directa muy fuerte entre las calificaciones previas (G1 y G2) y la calificación final (G3), así como relaciones moderadas con variables de constancia como studytime (tiempo de estudio semanal) y failures (fracasos anteriores).

A través de MinedApp, se configuraron y aplicaron las siguientes técnicas de preparación de datos:

- **Tratamiento de Nulos:** No se requirió imputación al no existir valores faltantes.
- **Tratamiento de Outliers:** Se conservaron los valores originales, ya que representan dinámicas reales de los estudiantes.
- **Escalado de Variables Numéricas:** Se mantuvo sin escalar (*Sin escalar*), preservando la interpretabilidad directa de las escalas originales (como las notas de 0 a 20).
- **Codificación Categórica:** Aplicación de **One-Hot Encoding** (*pd.get_dummies*) para transformar las variables de texto en estructuras binarias aptas para el algoritmo.

5. Modelo y evaluación

- **Algoritmo seleccionado:** Árbol de Decisión para Regresión (*Decision Tree Regressor*).
- **División de Datos:** 80% para el conjunto de entrenamiento (X_train, y_train) y 20% para la prueba (X_test, y_test), utilizando una semilla aleatoria fija (random_state=42).
- **Variables Predictoras:** studytime, absences, failures, G1, G2, freetime, goout, entre otras características demográficas y académicas.

El modelo fue evaluado mediante métricas estándar de rendimiento para tareas de regresión:

- **MAE (Error Absoluto Medio):** Mide la magnitud promedio de los errores absolutos en las predicciones de notas.
- **MSE (Error Cuadrático Medio):** Cuadra los errores para penalizar de forma más severa las desviaciones grandes.
- **RMSE (Raíz del Error Cuadrático Medio):** Devuelve el error en las mismas unidades de la escala de calificaciones original (0 a 20).
- **R^2 (Coeficiente de Determinación):** Evalúa la proporción de varianza de la nota final (G3) explicada por el modelo.

Interpretación: El uso del árbol de decisión sobre las variables de estudio y notas parciales permite estimar con un margen de error acotado la calificación final,

evidenciando que la constancia y el seguimiento continuo de las notas previas (G1 y G2) guardan una relación directa con el éxito académico del estudiante.

6. Resultados e interpretación

El experimento demuestra que es técnicamente viable aplicar modelos de regresión para estimar el rendimiento académico utilizando variables de esfuerzo y seguimiento continuo. Sin embargo, las predicciones deben interpretarse como un ejercicio analítico sobre una muestra escolar específica, y no como una garantía absoluta del comportamiento de usuarios en un entorno web abierto.

Para **LexaVoxa**, el aprendizaje más importante es de carácter estratégico: integrar este tipo de lógica predictiva dentro de la plataforma web (desarrollada en Spring Boot y MongoDB) permitirá en futuras versiones alertar a tiempo a los usuarios sobre su nivel de riesgo académico y automatizar recomendaciones de estudio personalizadas.

7. Limitaciones y conclusiones

- **Limitaciones:**

  El dataset proviene de un contexto educativo secundario en Portugal, lo que difiere del entorno de una aplicación web de idiomas en Colombia.

  La alta dependencia de las notas previas (G1 y G2) condiciona la predicción temprana.

  Ausencia de variables nativas de interacción en tiempo real dentro de la plataforma actual.

- **Conclusiones:** El proyecto cumple satisfactoriamente con la integración del componente analítico de minería de datos. LexaVoxa establece una base funcional sólida sobre la cual se pueden incorporar analíticas avanzadas de seguimiento en futuras fases de desarrollo.

8. Referencias y repositorio

- **Datos:** UCI Machine Learning Repository. *Student Performance Dataset*. Disponible en: https://archive.ics.uci.edu/dataset/320/student+performance
- **Guía de apoyo:** Cuadrado Beltrán, C. C. (s. f.). *Guía práctica para completar los entregables del proyecto de aula*. Minería de Datos I.
- **Repositorio:** [Enlace al repositorio de GitHub del equipo LexaVoxa]