INFORME METODOLÓGICO

Minería de Datos | Proyecto de Aula LexaVoxa

1. Introducción y Definición del Problema

LexaVoxa es un aplicativo web orientado al aprendizaje de idiomas que busca contribuir a mejorar la motivación, la constancia y el seguimiento del progreso de los estudiantes durante su proceso de formación. Como parte de la integración del análisis de datos en el proyecto, este ejercicio explora cómo los registros históricos de rendimiento estudiantil pueden aportar a la comprensión y predicción del éxito académico de los estudiantes.

- **Nombre del proyecto:** LexaVoxa
- **Pregunta de análisis:** ¿Cómo se puede predecir la calificación final (G3) de un estudiante a partir de su tiempo de estudio semanal, ausencias y calificaciones previas en el dataset seleccionado?
- **Tipo de tarea:** Regresión
- **Variable objetivo:** G3 (Calificación final del período, escala de 0 a 20)

2. Fuente y Descripción de los Datos

La fuente de datos utilizada es el dataset "Student Performance" (*student-por.csv*) obtenido del UCI Machine Learning Repository, enfocado en el rendimiento académico en lengua portuguesa.

Parámetro	Detalle
Volumen	649 registros (filas) y 33 columnas
Variables Numéricas (16)	age, Medu, Fedu, traveltime, studytime, failures, famrel, freetime, goout, Dalc, Walc, health, absences, G1, G2, G3
Variables Categóricas (17)	school, sex, address, famsize, Pstatus, Mjob, Fjob, reason, guardian, schoolsup, famsup, paid, activities, nursery, higher, internet, romantic
Calidad de datos	El conjunto de datos original no presenta valores nulos. Las variables numéricas reflejan de forma consistente los hábitos y antecedentes académicos de los estudiantes.

Parámetro	Detalle
Privacidad	Se excluyeron variables o identificadores que comprometan información confidencial directa, enfocando el análisis exclusivamente en el comportamiento de estudio y rendimiento.

3. Preprocesamiento de Datos

A través de la herramienta MinedApp, se configuraron y aplicaron las siguientes técnicas de preparación de datos:

- **Tratamiento de Nulos:** No se requirió imputación al no existir valores faltantes en el dataset original.
- **Tratamiento de Outliers:** Se conservaron los valores originales (como el registro de ausencias), ya que representan comportamientos reales de los estudiantes dentro del entorno educativo y no errores de captura.
- **Escalado de Variables Numéricas:** Se mantuvo sin escalar (*Sin escalar*), preservando la interpretabilidad directa de las escalas originales (como las calificaciones de 0 a 20 o las horas de estudio).
- **Codificación Categórica:** Aplicación de **One-Hot Encoding** (*pd.get_dummies*) para transformar las variables de texto y atributos categóricos en estructuras binarias aptas para el modelado.

4. Modelado Predictivo

- **Algoritmo seleccionado:** Árbol de Decisión para Regresión (*Decision Tree Regressor*).
- **División de Datos:** 80% para el conjunto de entrenamiento (X_train, y_train) y 20% para la prueba (X_test, y_test).
- **Configuración:** Semilla aleatoria fija (random_state=42) para garantizar la reproducibilidad de los resultados.
- **Justificación:** El árbol de decisión permite capturar relaciones no lineales y complejas entre los hábitos de constancia (como studytime y absences) y las calificaciones previas, generando reglas interpretables que explican el rendimiento final.

5. Evaluación del Modelo

El modelo fue evaluado mediante métricas estándar de rendimiento para tareas de regresión:

Métrica	Descripción / Propósito
MAE (Error Absoluto Medio)	Mide la magnitud promedio de los errores absolutos en las predicciones de notas.
MSE (Error Cuadrático Medio)	Cuadra los errores para penalizar de forma más severa las desviaciones grandes.
RMSE (Raíz del Error Cuadrático Medio)	Devuelve el error en las mismas unidades de la escala de calificaciones original (0 a 20).
R^2 (Coeficiente de Determinación)	Evalúa la proporción de varianza de la nota final ($G3$) explicada por el modelo.

- **Interpretación:** El uso del árbol de decisión sobre las variables de estudio y notas parciales permite estimar con un margen de error acotado la calificación final, evidenciando que la constancia y el seguimiento continuo de las notas previas ($G1$ y $G2$) guardan una relación directa con el éxito académico del estudiante.

6. Conclusiones y Recomendaciones

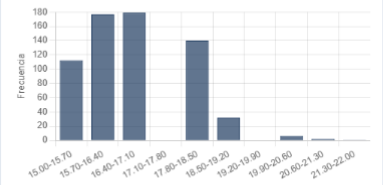
Es técnicamente viable aplicar modelos de regresión para estimar el rendimiento académico estudiantil utilizando variables de esfuerzo y seguimiento continuo.

El aprendizaje principal para **LexaVoxa** es de carácter estratégico: integrar este tipo de lógica predictiva dentro de la plataforma web (desarrollada en Spring Boot y MongoDB) permitirá alertar a tiempo a los usuarios sobre su nivel de riesgo y automatizar recomendaciones de estudio.

(Informe generado a partir de las evidencias y decisiones registradas en MinedApp para el Proyecto de Aula LexaVoxa)

7. Evidencias

Histograma de:



Matriz de correlación (numéricas)

	age	Medu	Fedu	traveltime	studytime	failures	famrel	freetime	goout	Dalc	Walc	health	absences	G1	G2	G3
age	1.00	-0.11	-0.12	0.03	-0.01	0.32	-0.02	-0.00	0.11	0.13	0.09	-0.01	0.15	-0.17	-0.11	-0.11
Medu	-0.11	1.00	0.65	-0.27	0.10	-0.17	0.02	-0.02	0.01	-0.01	-0.02	0.00	-0.01	0.26	0.26	0.24
Fedu	-0.12	0.65	1.00	-0.21	0.05	-0.17	0.02	0.01	0.03	0.00	0.04	0.04	0.03	0.22	0.23	0.21
traveltime	0.03	-0.27	-0.21	1.00	-0.06	0.10	-0.01	0.00	0.06	0.09	0.06	-0.05	-0.01	-0.15	-0.15	-0.13
studytime	-0.01	0.10	0.05	-0.06	1.00	-0.15	-0.00	-0.07	-0.08	-0.14	-0.21	-0.06	-0.12	0.26	0.24	0.25
failures	0.32	-0.17	-0.17	0.10	-0.15	1.00	-0.06	0.11	0.05	0.11	0.08	0.04	0.12	-0.38	-0.39	-0.39
famrel	-0.02	0.02	0.02	-0.01	-0.00	-0.06	1.00	0.13	0.09	-0.08	-0.09	0.11	-0.09	0.05	0.09	0.06
freetime	-0.00	-0.02	0.01	0.00	-0.07	0.11	0.13	1.00	0.35	0.11	0.12	0.08	-0.02	-0.09	-0.11	-0.12
goout	0.11	0.01	0.03	0.06	-0.08	0.05	0.09	0.35	1.00	0.25	0.39	-0.02	0.09	-0.07	-0.08	-0.09
Dalc	0.13	-0.01	0.00	0.09	-0.14	0.11	-0.08	0.11	0.25	1.00	0.62	0.06	0.17	-0.20	-0.19	-0.20
Walc	0.09	-0.02	0.04	0.06	-0.21	0.08	-0.09	0.12	0.39	0.62	1.00	0.11	0.16	-0.16	-0.16	-0.18
health	-0.01	0.00	0.04	-0.05	-0.06	0.04	0.11	0.08	-0.02	0.06	0.11	1.00	-0.03	-0.05	-0.08	-0.10
absences	0.15	-0.01	0.03	-0.01	-0.12	0.12	-0.09	-0.02	0.09	0.17	0.16	-0.03	1.00	-0.15	-0.12	-0.09
G1	-0.17	0.26	0.22	-0.15	0.26	-0.38	0.05	-0.09	-0.07	-0.20	-0.16	-0.05	-0.15	1.00	0.86	0.83
G2	-0.11	0.26	0.23	-0.15	0.24	-0.39	0.09	-0.11	-0.08	-0.19	-0.16	-0.08	-0.12	0.86	1.00	0.92
G3	-0.11	0.24	0.21	-0.13	0.25	-0.39	0.06	-0.12	-0.09	-0.20	-0.18	-0.10	-0.09	0.83	0.92	1.00

Estadísticas descriptivas

Métrica	age	Medu	Fedu	traveltime	studytime	failures	famrel	freetime	goout	Dalc	Walc	health	absences	G1
count	649.000	649.000	649.000	649.000	649.000	649.000	649.000	649.000	649.000	649.000	649.000	649.000	649.000	64
mean	16.744	2.515	2.307	1.569	1.931	0.222	3.931	3.180	3.185	1.502	2.280	3.536	3.659	11.
std	1.217	1.134	1.099	0.748	0.829	0.593	0.955	1.050	1.175	0.924	1.283	1.445	4.637	2.7
min	15.000	0.000	0.000	1.000	1.000	0.000	1.000	1.000	1.000	1.000	1.000	1.000	0.000	0.0
25%	16.000	2.000	1.000	1.000	1.000	0.000	4.000	3.000	2.000	1.000	1.000	2.000	0.000	10.
50%	17.000	2.000	2.000	1.000	2.000	0.000	4.000	3.000	3.000	1.000	2.000	4.000	2.000	11.
75%	18.000	4.000	3.000	2.000	2.000	0.000	5.000	4.000	4.000	2.000	3.000	5.000	6.000	13.
max	22.000	4.000	4.000	4.000	4.000	3.000	5.000	5.000	5.000	5.000	5.000	5.000	32.000	19.

Estadísticas descriptivas

u	Fedu	traveltime	studytime	failures	famrel	freetime	goout	Dalc	Walc	health	absences	G1	G2	G3
00	649.000	649.000	649.000	649.000	649.000	649.000	649.000	649.000	649.000	649.000	649.000	649.000	649.000	649.000
	2.307	1.569	1.931	0.222	3.931	3.180	3.185	1.502	2.280	3.536	3.659	11.399	11.570	11.906
	1.099	0.748	0.829	0.593	0.955	1.050	1.175	0.924	1.283	1.445	4.637	2.743	2.911	3.228
	0.000	1.000	1.000	0.000	1.000	1.000	1.000	1.000	1.000	1.000	0.000	0.000	0.000	0.000
	1.000	1.000	1.000	0.000	4.000	3.000	2.000	1.000	1.000	2.000	0.000	10.000	10.000	10.000
	2.000	1.000	2.000	0.000	4.000	3.000	3.000	1.000	2.000	4.000	2.000	11.000	11.000	12.000
	3.000	2.000	2.000	0.000	5.000	4.000	4.000	2.000	3.000	5.000	6.000	13.000	13.000	14.000
	4.000	4.000	4.000	3.000	5.000	5.000	5.000	5.000	5.000	5.000	32.000	19.000	19.000	19.000

8. Código de Python

```
# ========================================
# Script completo generado
# Guía Interactiva de Minería de Datos
# ========================================

# --- Preprocesamiento ---
import pandas as pd
import numpy as np
from sklearn.preprocessing import StandardScaler, MinMaxScaler, RobustScaler, OneHotEncoder, LabelEncoder

# Cargar datos
df = pd.read_csv("student-por.csv")
print("Filas x Columnas:", df.shape)

# One-Hot Encoding
cat_cols = df.select_dtypes(include=[object, category]).columns
df = pd.get_dummies(df, columns=cat_cols, drop_first=True)

print("Después de preprocesar:", df.shape)
print(df.head())

# --- Modelado ---
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeRegressor
```

```
# Definir X e y
y = df['G3']
X = df.drop(columns=['G3'])

# Train/test split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Modelo: Árbol de Decisión
model = DecisionTreeRegressor(random_state=42)
model.fit(X_train, y_train)
y_pred = model.predict(X_test)

print("Predicciones (primeras 10):", y_pred[:10])

# --- Evaluación ---
from sklearn import metrics

from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

print("MAE:", mean_absolute_error(y_test, y_pred))
print("MSE:", mean_squared_error(y_test, y_pred))
print("RMSE:", mean_squared_error(y_test, y_pred, squared=False))
print("R²:", r2_score(y_test, y_pred))
```